Zaawansowane modele liniowe — Raport z listy 2

Oliwia Turek

2026-04-18

Spis Treści

1 Podstawy teoretyczne **2**
1.1 Regresja Poissona 2
1.2 Wiarygodność 2
1.3 Interakcje 2
1.4 Test ilorazu wiarygodności 2
1.5 Test Walda 3

2 Zadania **4**
2.1 Zadanie 1 - Opis danych. 4
2.2 Zadanie 2 - Analiza wykresów. 4
2.3 Zadanie 3 – Pełny model Poissona z interakcjami. 7
2.4 Zadanie 4 - Uproszczenie modelu poprzez agregację zmiennych. 7
2.5 Zadanie 5 - Wyznaczenie wartości predyktora liniowego dla podgrup. 8
2.6 Zadanie 6 - Test równości predyktorów liniowych w weekend. 8
2.7 Zadanie 7 - Planowanie liczby pracowników na podstawie średniej liczby klientów. 9

1 Podstawy teoretyczne

1.1 Regresja Poissona

Niech $Y_1, \dots, Y_n$ będą niezależnymi zmiennymi losowymi takimi, że $Y_i \sim \text{Poisson}(\mu_i)$ dla $i = 1, \dots, n$. Wtedy model przyjmuje postać:

$$\log(\mu_i) = x_i^T \beta \quad \Longleftrightarrow \quad \mu_i = \exp(x_i^T \beta),$$

a predyktor liniowy:

$$\eta_i = x_i^T \beta = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{i,p-1}.$$

1.2 Wiarygodność

Dla badanej próby funkcja wiarygodności ma postać

$$L(\beta) = \prod_{i=1}^{n} \frac{\mu_i^{y_i} e^{-\mu_i}}{y_i!},$$

a jej logarytm wynosi

$$\ell(\beta) = \sum_{i=1}^{n} \left(y_i \log \mu_i - \mu_i - \log(y_i!) \right).$$

Wartość estymatora największej wiarygodności parametru β możemy wyznaczyć jako maksimum funkcji log-wiarygodności

$$\hat{\beta} = \arg\max_{\beta} \ell(\beta),$$

które w praktyce znajduje się numerycznie, ponieważ nie istnieje jego jawna postać analityczna.

1.3 Interakcje

Jeżeli w modelu uwzględniamy interakcje, to do predyktora liniowego wchodzą również iloczyny odpowiednich zmiennych objaśniających. Przykładowo dla dwóch zmiennych zapis ogólny ma postać

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i1} x_{i2}.$$

1.4 Test ilorazu wiarygodności

Niech M_0 oraz M_1 będą modelami zagnieżdżonymi, przy czym $M_0 \subset M_1$. Test ilorazu wiarygodności opiera się na statystyce *Deviance*

$$D(M) = 2\big(\ell(\hat{\beta}_1) - \ell(\hat{\beta}_0)\big),$$

gdzie $\ell(\hat{\beta}_1)$ jest wartością log-wiarygodności modelu saturowanego, a $\ell(\hat{\beta}_0)$ wartością log-wiarygodności modelu zredukowanego.

Przy prawdziwości hipotezy zerowej

$$H_0 : M_0 \text{ jest modelem wystarczającym}$$

statystyka D ma asymptotycznie rozkład

$$D \sim \chi^2_r,$$

gdzie r jest różnicą liczby parametrów w obu modelach.

1.5 Test Walda

Do testowania hipotezy

$$H_0 : C\beta = d$$

używamy statystyki

$$W = (C\hat{\beta} - d)^T (C\widehat{\mathrm{Var}}(\hat{\beta})C^T)^{-1}(C\hat{\beta} - d),$$

przy czym, gdy H_0 jest prawdziwa zachodzi

$$W \sim \chi^2_q, \qquad q = \mathrm{rank}(C).$$

2 Zadania

2.1 Zadanie 1 - Opis danych.

Zbiór danych *sklep* zawiera cztery kolumny:

- *no_clients* – liczba klientów obsłużonych w danej godzinie (wartości: $0, 1, 2, \ldots$),
- *day* – dzień tygodnia (wartości: poniedziałek, wtorek, ..., niedziela),
- *hour* – godzina (wartości: $8, 9, \ldots, 23$),
- *events* – informacja o tym, czy w danym dniu miało miejsce wydarzenie sportowe (*event*, wartości: 0 – nie, 1 – tak).

Dane przeanalizujemy za pomocą regresji Poissona, traktując liczbę obsłużonych klientów jako zmienną objaśnianą y, a pozostałe zmienne jako potencjalne predyktory.

2.2 Zadanie 2 - Analiza wykresów.

Dokonaj wstępnej analizy danych: sporządź boxploty zmiennej *y* względem predyktorów oraz wykresy zależności liczby klientów od godziny z uwzględnieniem dnia i wydarzeń sportowych. Opisz wpływ zmiennych, oceń znaczenie *events* oraz rozważ możliwość agregacji dni i godzin.

Analiza wykresów zależności liczby klientów y w zależności od każdego predyktora osobno

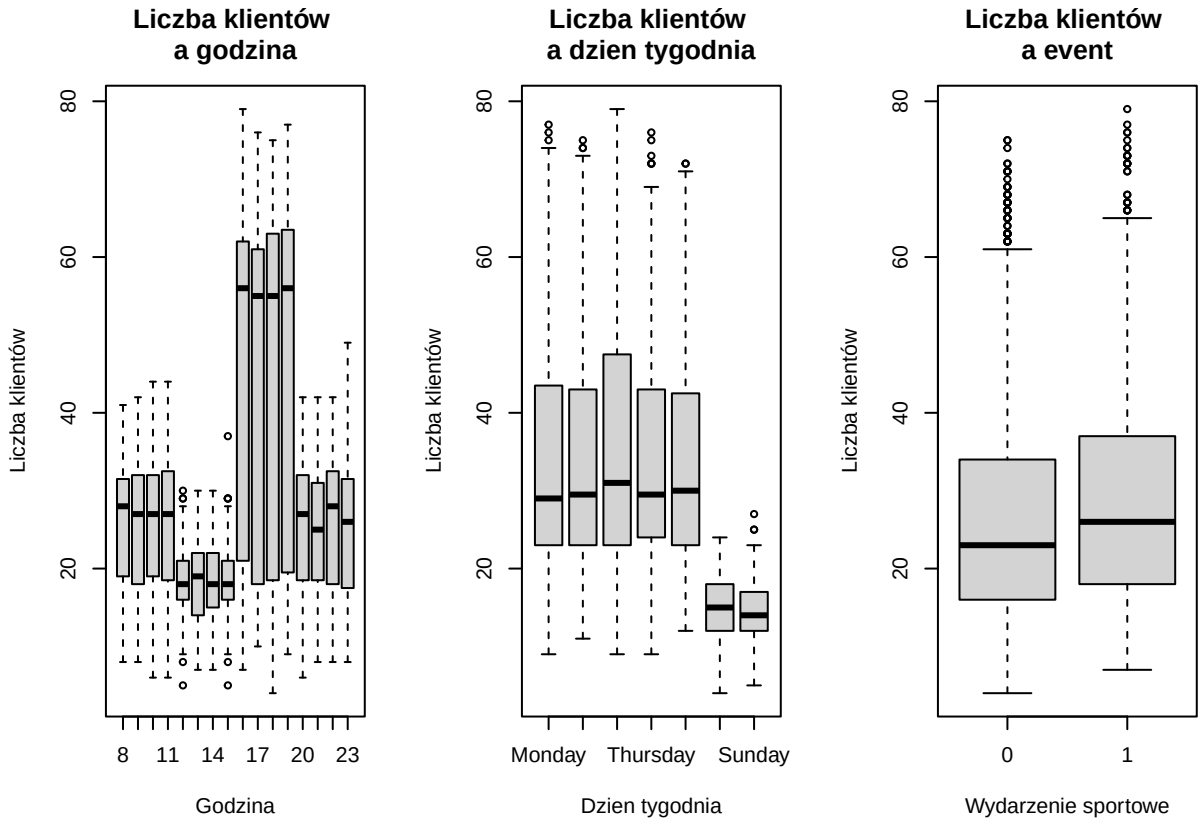

Komentarz: Z wykresów boxplot wyraźnie można zauważyć różnice w rozkładzie liczby klientów w zależności

od analizowanych predyktorów.

Najsilniejszą zależność obserwujemy względem zmiennej *hour*. Liczba klientów rośnie wraz z godziną dnia, osiągając maksimum w godzinach popołudniowych i wieczornych (około 16–20). W tych godzinach widoczne jest również większe zróżnicowanie wartości, co sugeruje większą zmienność natężenia ruchu.

W przypadku zmiennej *day* widoczny jest podział na dni robocze oraz weekend. W dni robocze liczba klientów jest wyższa i bardziej zróżnicowana, natomiast w weekend obserwujemy niższe i bardziej stabilne wartości. Sugeruje to możliwość pogrupowania dni na dwie kategorie: dni robocze oraz weekend.

Dla zmiennej *events* różnice są znacznie mniej wyraźne. Rozkłady liczby klientów dla dni z wydarzeniem i bez wydarzenia są podobne, choć można zauważyć niewielkie przesunięcie w kierunku większych wartości dla dni z wydarzeniem. Wpływ tej zmiennej wydaje się jednak słabszy niż w przypadku *hour* i *day*.

Na wszystkich wykresach widoczne są obserwacje odstające, co wskazuje na sporadyczne występowanie nietypowo dużego ruchu klientów. Dodatkowo wariancja liczby klientów wydaje się rosnąć wraz ze średnią, co jest zgodne z założeniami modelu Poissona.

Analiza wykresów zależności liczby klientów od godziny z uwzględnieniem dnia i wydarzeń

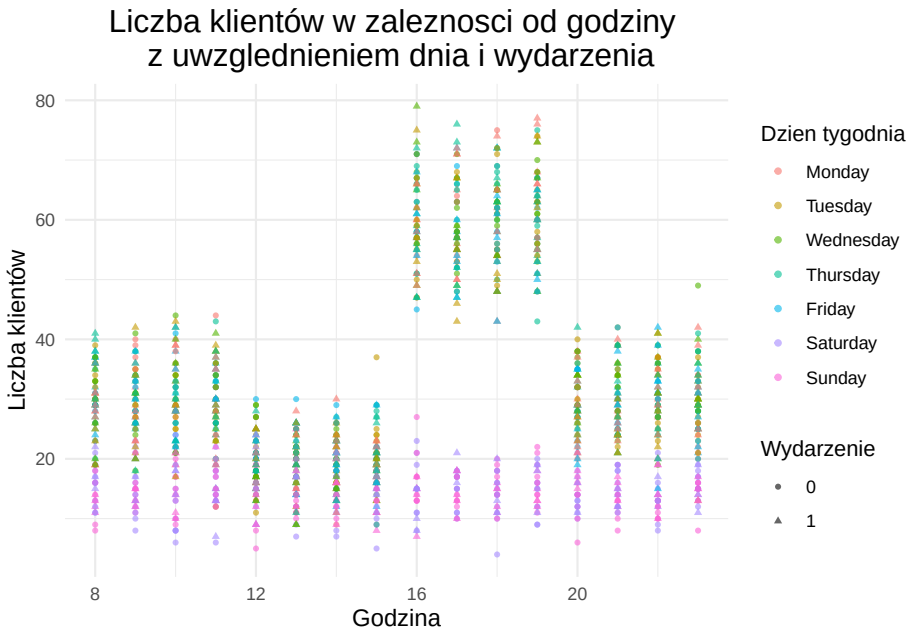

Komentarz: Wykres pokazuje zależność liczby klientów od godziny z jednoczesnym uwzględnieniem dnia tygodnia oraz występowania wydarzenia sportowego. Łatwo zauważyć, że największe różnice dotyczą przede wszystkim dni tygodnia i pory dnia, natomiast wpływ wydarzeń sportowych nie wydaje się znaczny.

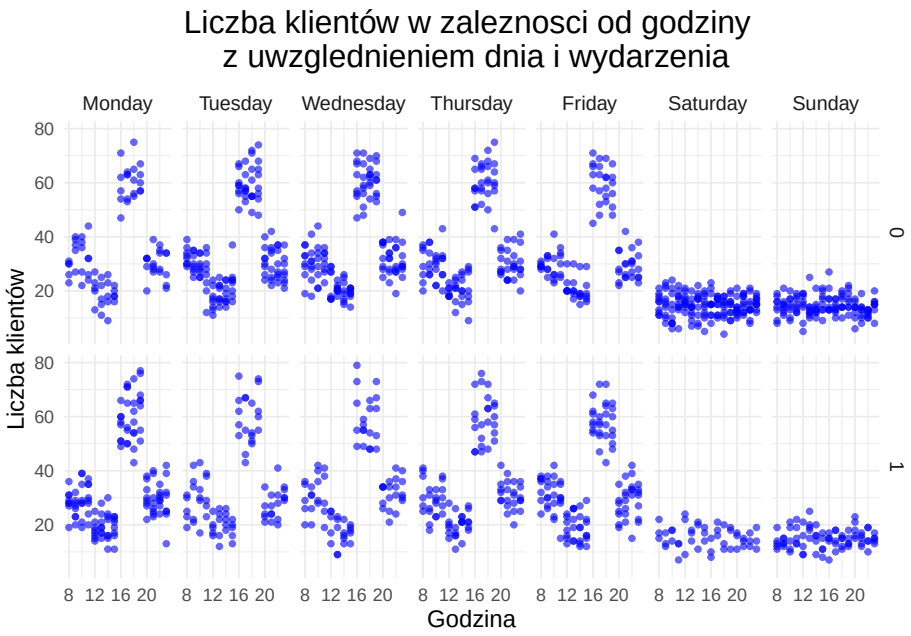

Komentarz: Możemy zauważyć, że zmienna *events* nie zmienia istotnie kształtu zależności między liczbą klientów a godziną. Profile dla dni z wydarzeniami i bez nich są bardzo podobne, co sugeruje brak istotnych interakcji z pozostałymi zmiennymi.

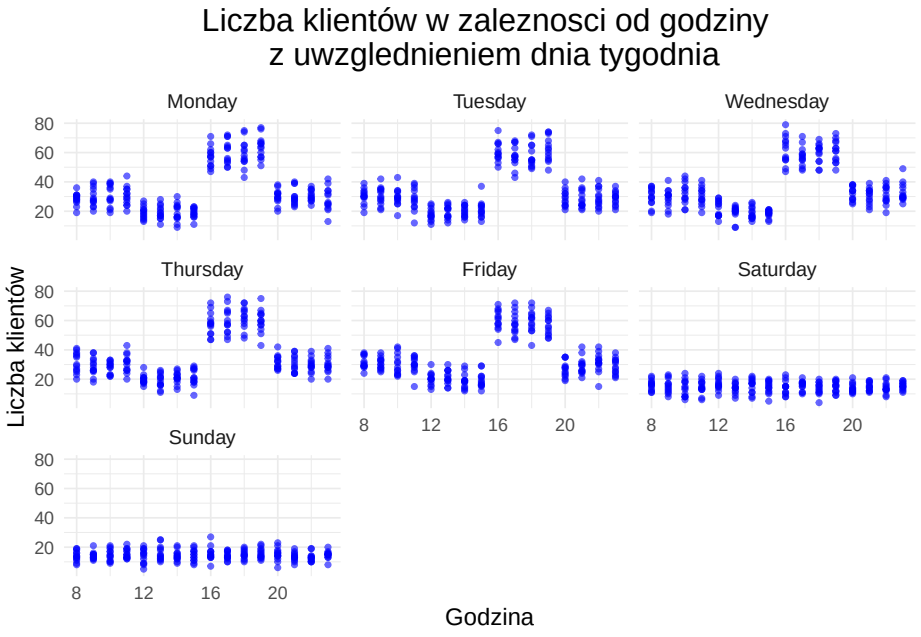

Wykres z podziałem na dni tygodnia potwierdza, że liczba klientów zmienia się przede wszystkim w zależności od godziny oraz rodzaju dnia. Dla dni roboczych widoczny jest wyraźny wzrost liczby klientów w godzinach popołudniowych, natomiast w weekend liczba klientów jest niższa i bardziej równomiernie rozłożona w ciągu dnia. Wzorce te są spójne w obrębie poszczególnych dni.

Analiza powyższych wykresów uwzględniających jednocześnie godzinę, dzień tygodnia oraz wydarzenia sportowe wskazuje, że główną rolę odgrywają zmienne *hour* oraz *day*. Dodatkowo wykresy z podziałem na dni tygodnia

potwierdzają możliwość redukcji liczby kategorii poprzez:

- agregację dni do dwóch grup: dni robocze i weekend,
- agregację godzin do przedziałów ok. czterogodzinnych o podobnym poziomie natężenia ruchu.

2.3 Zadanie 3 – Pełny model Poissona z interakcjami.

Skonstruuj model Poissona z pełną interakcją między regresorami (jako faktorami). Podaj liczbę parametrów oraz liczbę parametrów związanych ze zmienną *events*. Zbadaj istotność zmiennej *events* oraz interakcji.

Komentarz: Przyjmujemy poziom istotności $\alpha = 0.05$.

Model Poissona z interakcją pomiędzy wszystkimi regresorami, przy traktowaniu każdej zmiennej jako faktora, zawiera 223 parametry poza wyrazem wolnym. Parametry związane ze zmienną *events* stanowią 112 elementów macierzy planu. Obejmują one zarówno efekt główny tej zmiennej, jak i wszystkie interakcje, w których ona występuje.

Istotność zmiennej *events* badamy poprzez porównanie modelu bez tej zmiennej z modelem pełnym za pomocą testu anova. Otrzymana wartość p wynosi 0.3755 w związku z czym nie mamy podstaw do odrzucenia hipotezy zerowej o braku istotności zmiennej. Oznacza to, że możemy założyć iż zmienna *events* nie jest istotna statystycznie.

Ponieważ zmienna *events* okazała się nieistotna, dalszą analizę interakcji ograniczamy do zmiennych *day* i *hour*. W szczególności badamy istotność interakcji między tymi zmiennymi poprzez porównanie modelu z interakcją *day* $\times$ *hour* z modelem addytywnym (bez interakcji). Otrzymana p-wartość wynosi ≈ 0, co oznacza, że interakcja *day* $\times$ *hour* jest istotna statystycznie.

2.4 Zadanie 4 - Uproszczenie modelu poprzez agregację zmiennych.

Utwórz zmienne agregujące dzień (roboczy/weekend) i godzinę (przedziały 4-godzinne), a następnie skonstruuj model Poissona z interakcją między nimi. Określ liczbę parametrów i sprawdź, czy model różni się istotnie od modelu pełnego.

Komentarz: Redukujemy liczbę parametrów poprzez agregację zmiennych:

- zmienna *day* została sprowadzona do dwóch kategorii: dni roboczych (poniedziałek-piątek) oraz weekendu (sobota-niedziela),
- zmienna *hour* została podzielona na cztery przedziały czterogodzinne, przy czym np. przedział 8–12 oznacza godziny od 8:00 do 11:59.

Taki sposób agregacji jest uzasadniony wynikami wcześniejszej analizy wykresów..

Na podstawie nowych zmiennych konstruujemy model Poissona z interakcją, który zawiera 7 parametrów poza wyrazem wolnym. W porównaniu z modelem pełnym, zawierającym 223 parametry, oznacza to redukcję liczby parametrów około 32-krotnie.

Aby sprawdzić, czy model uproszczony nie traci istotnie na jakości dopasowania względem modelu pełnego z Zadania 3, porównujemy oba modele za pomocą testu ilorazu wiarygodności, wykonanego funkcją *anova(..., test*

= *"Chisq")*. Testowane hipotezy mają postać:

$$H_0 : \text{brak istotnych różnic między modelami} \quad \text{vs} \quad H_1 : \text{model pełny opisuje dane istotnie lepiej.}$$

Otrzymana wartość p wynosi 0.8694, co oznacza brak podstaw do odrzucenia hipotezy zerowej. Możemy zatem uznać, że uproszczony model opisuje dane równie dobrze jak model pełny, przy znacznie mniejszej liczbie parametrów.

2.5 Zadanie 5 - Wyznaczenie wartości predyktora liniowego dla podgrup.

Stwórz tabelę dla modelu z zadania 4, zawierającą podgrupy wyznaczone przez typ dnia i przedział godzinowy, odpowiadające im średnie liczby klientów oraz postać i wartość predyktora liniowego dla każdej podgrupy.

Tabela 1: Wyniki modelu Poissona dla podgrup dnia i godzin

Dzień i godzina	Średnia liczba klientów	Postać predyktora	Wartość predyktora
roboczy 8-12	30.01	β0	3.401
roboczy 12-16	19.71	β0 + β2	2.981
roboczy 16-20	59.64	β0 + β3	4.088
roboczy 20-24	29.98	β0 + β4	3.401
weekend 8-12	14.79	β0 + β1	2.694
weekend 12-16	14.95	β0 + β1 + β2 + β5	2.705
weekend 16-20	14.87	β0 + β1 + β3 + β6	2.699
weekend 20-24	14.37	β0 + β1 + β4 + β7	2.665

Komentarz: Tabela przedstawia wartości modelu Poissona dla podgrup wyznaczonych przez typ dnia i przedział godzinowy. W pierwszym wierszu znajdują się podgrupy, w drugim odpowiadające im średnie liczby klientów, natomiast w trzecim i czwartym postać oraz wartość predyktora liniowego η_i.

Współczynniki modelu interpretujemy następująco: β_0 odpowiada grupie bazowej (dzień roboczy, godziny 8–12), β_1 opisuje wpływ weekendu, $\beta_2, \beta_3, \beta_4$ odpowiadają kolejnym przedziałom godzinowym, natomiast $\beta_5, \beta_6, \beta_7$ opisują interakcje weekendu z tymi przedziałami.

Wyniki potwierdzają wnioski z analizy wykresów: najwyższą średnią liczbę klientów obserwujemy w dni robocze w godzinach 16–20, natomiast w weekend przewidywana liczba klientów jest niższa i bardziej wyrównana. Oznacza to, że pora dnia silniej różnicuje ruch klientów w dni robocze niż w weekend.

2.6 Zadanie 6 - Test równości predyktorów liniowych w weekend.

Sprawdź, czy predyktory liniowe dla podgrup godzinowych w weekend są równe, wykorzystując test Walda.

Komentarz: Przyjmujemy poziom istotności $\alpha = 0.05$.

Analiza wstępna oraz wyniki przedstawione w tabeli sugerują, że w weekend liczba klientów jest zbliżona niezależnie od pory dnia. W celu sprawdzenia tej obserwacji przeprowadzimy test Walda, badający równość predyktorów liniowych η_i dla wszystkich przedziałów godzinowych w weekend.

Testujemy hipotezę zerową:

$$H_0 : \eta_{\text{weekend},8\text{–}12} = \eta_{\text{weekend},12\text{–}16} = \eta_{\text{weekend},16\text{–}20} = \eta_{\text{weekend},20\text{–}24},$$

która jest równoważna układowi:

$$\begin{cases} \beta_2 + \beta_5 = 0 \\ \beta_3 + \beta_6 = 0 \\ \beta_4 + \beta_7 = 0 \end{cases}$$

czyli brakowi wpływu przedziału godzinowego na liczbę klientów w weekend.

Tabela 2: Wyniki testu Walda dla równości predyktorów liniowych w weekend

Model	Stopnie swobody	Różnica df	Statystyka chi-kwadrat	p-wartość
Model ograniczony	1451	NA	NA	NA
Model pełny	1448	3	1.383	0.7095

Otrzymana wartość *p* wynosi 0.7095, co oznacza brak podstaw do odrzucenia hipotezy zerowej. W konsekwencji nie ma podstaw do zakładania istotnych różnic między predyktorami liniowymi dla poszczególnych godzin w weekend.

Wynik ten potwierdza, że w weekend liczba klientów pozostaje na zbliżonym poziomie niezależnie od godziny.

2.7 Zadanie 7 - Planowanie liczby pracowników na podstawie średniej liczby klientów.

Właściciel sklepu poprosił, abyś na podstawie wyników tabeli zaplanował optymalną liczbę pracowników oraz grafik pracy. W tym celu załóż, że w ciągu godziny jeden pracownik jest w stanie obsłużyć do 20 klientów.

Tabela 3: Plan liczby pracowników w zależności od dnia i godziny

Dzień i godzina	Średnia liczba klientów	Liczba pracowników
roboczy 8-12	30.01	2
roboczy 12-16	19.71	1
roboczy 16-20	59.64	3
roboczy 20-24	29.98	2
weekend 8-12	14.79	1
weekend 12-16	14.95	1
weekend 16-20	14.87	1
weekend 20-24	14.37	1

Komentarz: Na podstawie średniej liczby klientów wyznaczono minimalną liczbę pracowników. Największe zapotrzebowanie występuje w dni robocze w godzinach 16–20, natomiast w weekend wystarcza jeden pracownik.